Урок 1

1. Разверните у себя hadoop кластер внутри docker контейнера
2. Проверьте работоспособность кластера, посмотрев на статус ресурс менеджера, нейм ноды и дата ноды
3. Остановите кластер
4. Вы пришли в компанию, в которой планируют строить Data Lake и DWH с нуля. Текущих данных около 15 Тб. Ежегодный прирост данных составляет ~500 Гб. Какую технологию вы бы предложили использовать и почему?

Задание 1

Поднимаем контейнер с кластером в интерактивном режиме

```
docker run -it --name gbhdp \ -p 50090:50090 \ -p 50075:50075 \ -p 50070:50070 \ -p 8042:8042 \ -p 8088:8088 \ -p 8888:8888 \ -p 4040:4040 \ -p 4044:4044 \ --hostname localhost \ img-hdp-hadoop
```

```
/************************************************************
SHUTDOWN_MSG: Shutting down NameNode at localhost/127.0.0.1
************************************************************/
Starting namenodes on [localhost]
localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
localhost: starting namenode, logging to /home/hduser/hadoop/logs/hadoop-hduser-namenode-localhost.out
localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
localhost: starting datanode, logging to /home/hduser/hadoop/logs/hadoop-hduser-datanode-localhost.out
Starting secondary namenodes [0.0.0.0]
0.0.0.0: Warning: Permanently added '0.0.0.0' (ECDSA) to the list of known hosts.
0.0.0.0: starting secondarynamenode, logging to /home/hduser/hadoop/logs/hadoop-hduser-secondarynamenode-localhost.out
starting yarn daemons
starting resourcemanager, logging to /home/hduser/hadoop/logs/yarn--resourcemanager-localhost.out
localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
localhost: starting nodemanager, logging to /home/hduser/hadoop/logs/yarn-hduser-nodemanager-localhost.out
hduser@localhost:~$
```

Задание 2

Ресурс менеджер

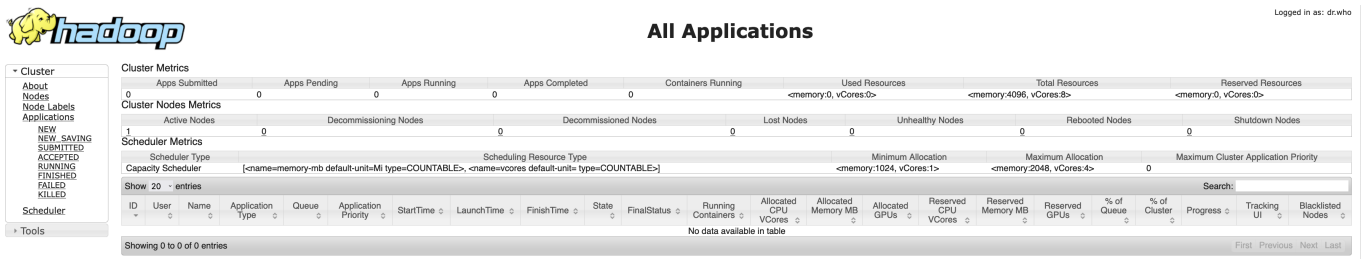

Нод менеджер

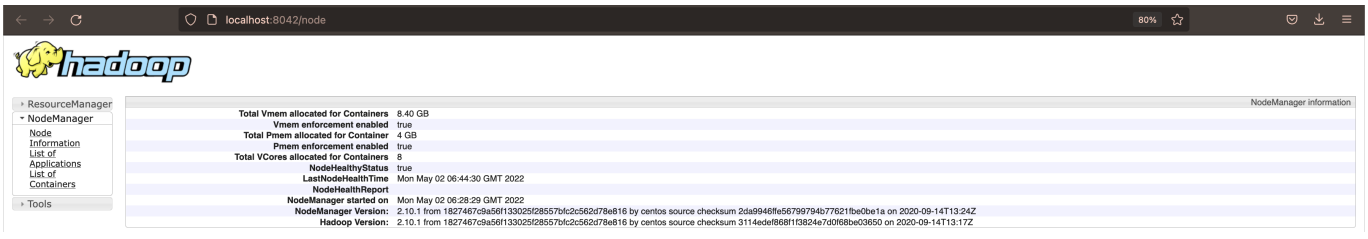

Нейм нода

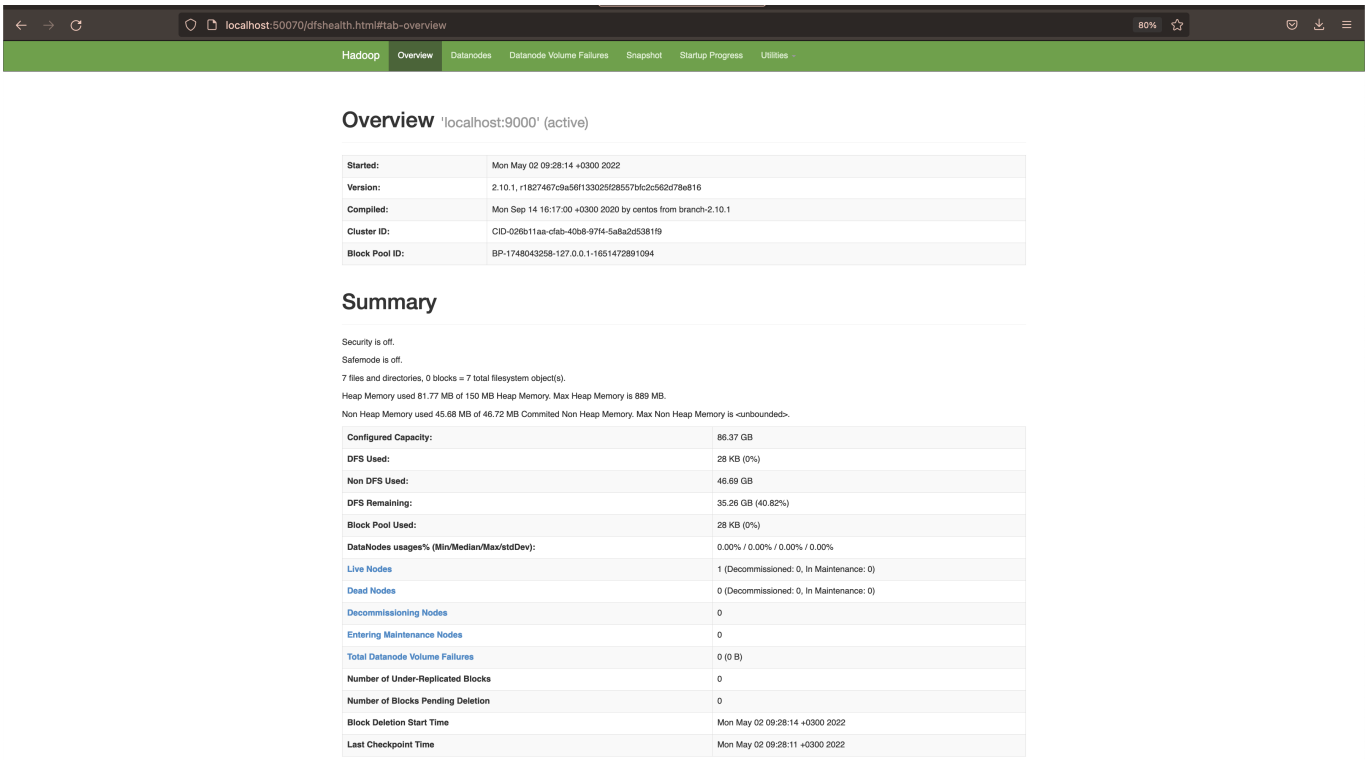

Дата нода

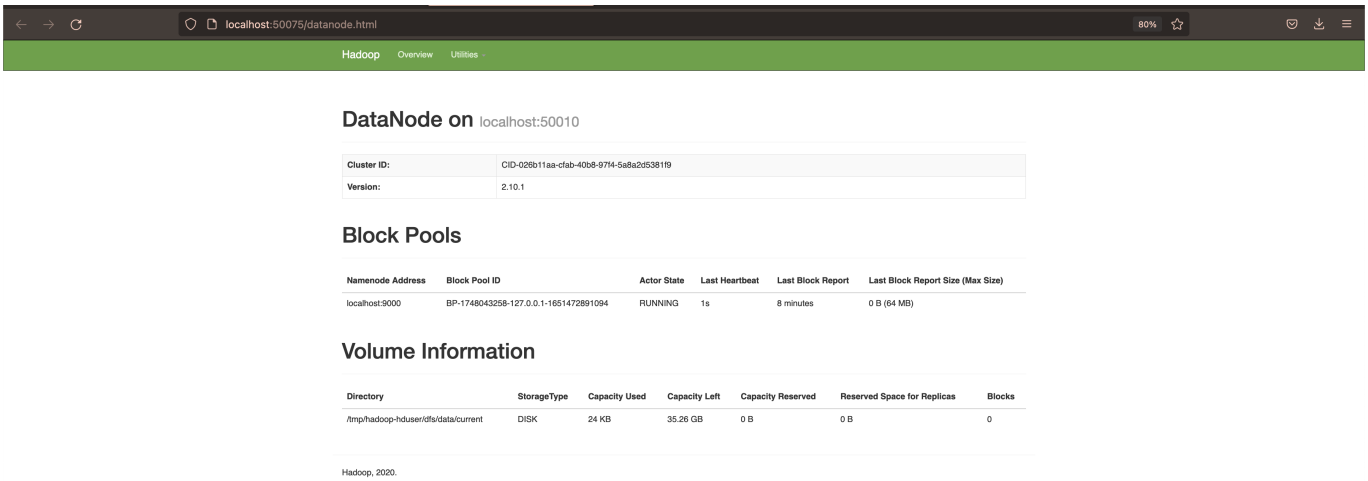

Задание 3

Выключаем кластер командой `exit`

```
hduser@localhost:~$ exit
exit
Stopping namenodes on [localhost]
localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
localhost: stopping namenode
localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
localhost: stopping datanode
Stopping secondary namenodes [0.0.0.0]
0.0.0.0: Warning: Permanently added '0.0.0.0' (ECDSA) to the list of known hosts.
0.0.0.0: stopping secondarynamenode
stopping yarn daemons
stopping resourcemanager
localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
localhost: stopping nodemanager
localhost: nodemanager did not stop gracefully after 5 seconds: killing with kill -9
no proxyserver to stop
Bye, bye!
```

Задание 4

В целом это зависит от самих данных. Если они реалиционные, то при таком приросте и изначальном объеме данных можно обойтись RDBMS. Если же данные малостроктурированы, то можно задуматься об использовании hadoop, хотя опять же при таком небольшом объеме и приросте данных это не очень целесообразно